南京信息工程大学
Nanjing University of Information Science & Technology

# Project Report
# 实验报告

## 实验编号：第二次实验报告

| 学号 | 团队成员 |
| --- | --- |
| 202283890036/W20109685 | 黄家睿 |
| | |
| | |
| | |

**Date：2025/3/25**

## 1、Project Overview（简要概述实验内容）

本次实验的核心目标是开发一个能够准确预测房屋销售价格的智能系统。我们收集了近 8 万条房屋交易数据，通过系统的数据分析和机器学习技术，训练出可以根据房屋各项特征自动估算售价的模型。整个实验过程就像是教计算机"读懂"房地产市场的规律：先给它看大量历史交易案例，让它学习不同房屋特征与售价之间的关系，最终它就能对从未见过的房屋给出合理的价格预测。

实验最终取得了不错的效果：我们训练出的最佳模型可以解释 80%以上的房价变化，平均预测误差仅为 10.77%，这意味着对于一套价值 100 万的房子，预测价格和实际价格的差距通常不超过 11 万，已经具备了实际应用价值。更重要的是，我们还找到了影响房价的核心因素，这能帮助我们更好地理解房地产市场的运行规律。

## 2、Methodology （详细介绍所采用的方法）

整个实验过程可以分为四个清晰的步骤，每个步骤都经过了精心设计，确保结果的准确性和可靠性：

**第一步：数据准备与清洗**

我们首先收集了总共 79,065 条房屋交易记录，每条记录包含 41 项房屋信息，比如房屋面积、卧室数量、地理位置、周边学校情况等等。这些原始数据就像是未经打磨的原石，里面有很多无用信息甚至错误信息，需要我们进行仔细清理：我们删除了对预测没有帮助的信息（比如房屋 ID、地址文本描述等），把文字描述的信息转换成计算机能理解的数字形式，还用合理的数值填补了缺失的数据。经过处理后，我们最终保留了 36 个最有价值的特征用于后续分析。

**第二步：特征工程**

仅仅使用原始数据还不够，我们还根据生活常识创造了几个更有意义的新特征：比如计算挂牌价和上次售价的差值来反映房价的变化趋势，计算每个卧室的平均面积来反映居住舒适度，计算卧室和浴室的比例来反映房屋布局的合理性。这些

新特征能够更准确地描述房屋的价值，就像我们在评估房价时不仅会看总面积，还会考虑户型是否合理一样。

**第三步：模型训练**

我们选择了五种目前最常用的机器学习算法进行对比测试，包括 XGBoost、LightGBM、极端随机树（Extra Trees）、随机森林和梯度提升算法。每种算法都有自己的特点，就像不同的专家有不同的分析思路。我们把 47,439 条训练数据按 8:2 的比例分成两部分：80%的数据用来"教"模型学习房价规律，剩下 20%的数据用来测试模型的学习效果，确保它不是死记硬背训练数据，而是真正掌握了普遍规律。

**第四步：模型评估与选择**

我们用三个指标来评估模型的好坏：首先是 $R^2$分数，衡量模型能够解释多少房价变化，最高是 100%，分数越高越好；其次是平均绝对误差，衡量预测价格和实际价格的平均差距，越小越好；最后是均方根误差，用来衡量模型对高价房屋的预测准确性。通过多轮测试和对比，我们最终选择了表现最稳定的极端随机树模型作为最终的预测模型。

## 3、Evaluation Setup（实验条件与设置）

为了保证实验结果的可靠性和可重复性，我们严格控制了整个实验的环境设置：

**数据集划分**：我们将全部数据分成了三个独立的部分：训练集包含 37,951 条记录，用来训练模型；验证集包含 9,488 条记录，用来调整模型参数和初步测试效果；测试集包含 31,626 条记录，完全不参与训练过程，只用来最终测试模型的真实性能。这种划分方式就像平时练习用的模拟题和最终考试用的真题完全分开，能最真实地反映模型的实际能力。

**数据预处理流程**：所有数值特征都进行了标准化处理，把不同量级的数据转换到相同的尺度上，这样不会出现因为某个特征数值特别大而过度影响模型的情况。

对于文本类型的特征（比如房屋类型、供暖方式等），我们采用了标签编码的方式转换成数字，同时把缺失值统一标记为"未知"，确保所有信息都能被有效利用。

**模型参数设置**：为了保证公平对比，所有模型的基础参数都设置在相同水平：树模型的数量都设置为 300 棵，最大深度根据算法特点设置在 5 到 20 之间，学习率统一设置为 0.05。我们还设置了随机种子为 42，确保每次运行实验都能得到完全相同的结果，方便后续验证和改进。

**评估方法**：我们采用了 5 折交叉验证的方法来评估模型的稳定性，就是把训练数据分成 5 份，每次用 4 份训练、1 份测试，重复 5 次，取平均结果。这种方法能够更准确地评估模型在不同数据上的表现，避免因为数据划分的偶然性导致结果偏差。

## 4、Evaluation Analysis （实验结果与分析）

经过系统的测试和评估，我们得到了非常有价值的实验结果，不仅验证了模型的预测能力，还揭示了房地产市场的一些内在规律：

**模型性能对比**

五种模型的表现差异比较明显，我们可以通过下表直观看到它们的性能对比：

| 模型名称 | 训练集 $R^2$ | 验证集 $R^2$ | 验证集平均误差 |
|---|---|---|---|
| 极端随机树(Extra Trees) | 99.82% | 80.15% | $139,829 |
| 随机森林(Random Forest) | 97.00% | 78.66% | $146,828 |
| LightGBM | 93.51% | 78.36% | $165,869 |
| 梯度提升(Gradient Boosting) | 98.23% | 78.20% | $148,137 |
| XGBoost | 98.60% | 63.66% | $154,678 |

可以看到，极端随机树模型在验证集上的表现最好，$R^2$达到 80.15%，平均误差也最低，说明它的泛化能力最强，最适合用来预测房价。值得注意的是，所有模型在训练集上的表现都很好，但在验证集上表现有明显差距，这说明有些模型出现

了"死记硬背"训练数据的情况，也就是我们常说的过拟合，而极端随机树在这方面表现得最好。

**影响房价的关键因素**

通过分析模型的特征重要性，我们找到了影响房价的十大核心因素，这些因素基本符合我们对房地产市场的常识认知：

| 排名 | 特征名称 | 重要性占比 | 说明 |
|---|---|---|---|
| 1 | 挂牌价 | 27.19% | 卖家最初的报价是最重要的参考 |
| 2 | 房产评估值 | 16.32% | 专业机构对房屋价值的评估 |
| 3 | 年度税费 | 16.10% | 每年需要缴纳的税费，反映房屋价值 |
| 4 | 价格差异 | 8.93% | 当前挂牌价与上次售价的差值 |
| 5 | 浴室数量 | 4.65% | 房屋内浴室的总数量 |
| 6 | 全浴室数量 | 4.46% | 带淋浴功能的完整浴室数量 |
| 7 | 室内面积 | 2.61% | 房屋内部可居住的总面积 |
| 8 | 上次售价 | 2.48% | 房屋上一次交易的价格 |
| 9 | 小学评分 | 1.24% | 周边小学的教学质量评分 |
| 10 | 卧室浴室比 | 1.20% | 卧室数量与浴室数量的比例 |

从这个结果可以看出，价格相关的三个特征（挂牌价、评估值、年度税费）合计占到了近 60%的重要性，说明价格类信息是影响房价的最核心因素。有意思的是，浴室数量的重要性超过了室内总面积，这说明在房地产市场中，浴室的数量和

质量可能比单纯的面积大小更受买家重视。而周边学校的评分也进入了前十，这也印证了学区房确实是影响房价的重要因素。

**预测结果分析**

我们用最终训练好的模型对 31,626 套测试房屋进行了价格预测，预测结果的统计信息如下：

- 最低预测价格：$138,864
- 最高预测价格：$29,593,134
- 平均预测价格：$900,799
- 中位数预测价格：$626,334

从这些数据可以看出，房价分布呈现明显的右偏特征，也就是大部分房屋价格集中在中等区间，少数高价房屋拉高了整体平均值。模型对中等价位的房屋预测准确度最高，对特别高或特别低的极端价格预测误差会稍大一些，这也是符合预期的，因为极端价格的房屋通常有特殊的影响因素，很难通过通用模型准确预测。

**模型优势与改进方向**

我们的模型已经具备了不错的实用价值，主要优势体现在：预测准确率较高，平均相对误差仅为 10.77%；模型稳定性好，在不同数据集上表现一致；特征重要性符合市场常识，结果具有可解释性。但也存在一些可以改进的地方：目前模型在训练集上表现过好，存在一定的过拟合问题；80.15%的 $R^2$距离我们设定的 85%的目标还有提升空间；对极端价格的预测准确性还有待提高。

未来我们可以从几个方面进一步优化：收集更多的训练数据，特别是稀有类型房屋的数据；尝试更多的特征组合，比如加入更详细的地理位置信息；进一步调整模型参数，减少过拟合；还可以尝试将多个模型的预测结果结合起来，进一步提高预测准确度。